

**DASHBOARD BI UNTUK ANALISIS DAN CLUSTERISASI
WILAYAH BERDASARKAN TINGKAT BANJIR DAN
PRODUKSI SAMPAH DI JAWA BARAT MENGGUNAKAN K-
MEANS**



Disusun oleh:

Azkia Al Hikam (2307033)

Nurul Aeni A.Z (2307049)

Deco Mahendra (2307036)

**JURUSAN TEKNIK INFORMATIKA
PROGRAM PRODI SISTEM INFORMASI KOTA CERDAS
POLITEKNIK NEGERI INDRAMAYU**

2026

I. PENDAHULUAN

1.1 Latar Belakang

Provinsi Jawa Barat merupakan salah satu wilayah dengan tingkat kepadatan penduduk yang tinggi di Indonesia, yang berdampak langsung pada meningkatnya permasalahan lingkungan, khususnya terkait banjir dan produksi sampah. Pertumbuhan penduduk yang pesat, urbanisasi yang tidak terkendali, serta minimnya pengelolaan lingkungan yang optimal menyebabkan berbagai wilayah di Jawa Barat rentan terhadap bencana banjir dan peningkatan volume sampah yang signifikan.

Permasalahan banjir di Jawa Barat seringkali disebabkan oleh berbagai faktor, seperti curah hujan tinggi, buruknya sistem drainase, alih fungsi lahan, serta terbebani nya sampah di sungai dan saluran udara. Di sisi lain, produksi sampah yang terus meningkat setiap harinya belum sepenuhnya diimbangi dengan sistem pengelolaan yang efektif. Banyak Tempat Pembuangan Sementara (TPS) yang mengalami kelebihan kapasitas, sehingga berdampak pada pencemaran lingkungan dan memperparah risiko banjir.

Dalam konteks pengambilan keputusan, pemerintah daerah memerlukan data yang akurat, terintegrasi, dan mudah dipahami untuk menentukan prioritas penanganan wilayah. Namun, data yang tersedia seringkali masih tersebar, tidak terstruktur, dan sulit dijelaskan secara cepat. Hal ini menghambat proses identifikasi wilayah prioritas yang membutuhkan penanganan segera.

Oleh karena itu, diperlukan suatu solusi berbasis teknologi yang mampu mengolah data menjadi informasi yang bermakna. Salah satu pendekatan yang dapat digunakan adalah dengan membangun Dashboard Business Intelligence (BI) yang dilengkapi dengan metode clustering K-Means. Metode ini dapat membantu mengelompokkan wilayah berdasarkan tingkat risiko banjir dan produksi sampah, sehingga mempermudah dalam menentukan strategi penanganan yang tepat.

Dengan adanya sistem ini, diharapkan dapat memberikan gambaran visual yang informatif dan mendukung pengambilan keputusan berbasis data (data-driven Decision Making), khususnya dalam upaya meningkatkan kualitas lingkungan dan mitigasi bencana di Jawa Barat.

1.2 Konteks Smart City

Konsep Smart City menekankan pada pemanfaatan teknologi informasi dan komunikasi untuk meningkatkan kualitas hidup masyarakat, efisiensi layanan publik, serta berkelanjutan lingkungan. Dalam konteks ini, pengelolaan banjir dan sampah termasuk dalam dimensi Smart Environment dan Smart Governance.

Penerapan Dashboard BI dengan analisis K-Means sejalan dengan konsep Smart City karena:

1. Mengintegrasikan data lingkungan secara digital
2. Menyediakan visualisasi data yang real-time dan interaktif
3. Mendukung pengambilan keputusan berbasis data
4. Meningkatkan respons pemerintah terhadap permasalahan lingkungan

1.3 Tujuan Analisis

Tujuan dari penelitian dan pengembangan sistem ini adalah sebagai berikut:

1. Mengolah data tingkat banjir dan produksi sampah di wilayah Jawa Barat menjadi informasi yang terstruktur dan mudah dianalisis.
2. Menerapkan metode K-Means Clustering untuk mengelompokkan wilayah berdasarkan tingkat risiko banjir dan volume sampah.
3. Membangun Dashboard Business Intelligence (BI) yang interaktif untuk memvisualisasikan hasil analisis.
4. Membantu pemerintah dalam menentukan prioritas wilayah yang membutuhkan penanganan lebih lanjut.
5. Mendukung pengambilan keputusan berbasis data dalam pengelolaan lingkungan.

II. KEBUTUHAN BISNIS

2.1 Stakeholder

Sistem Dashboard BI ini dirancang untuk digunakan oleh beberapa stakeholder utama, yaitu:

1. Pemerintah Daerah (Pemda Jawa Barat)

Pengguna utama dalam pengambilan kebijakan dan memanfaatkan dashboard untuk menentukan prioritas penanganan wilayah.

2. Dinas Lingkungan Hidup (DLH)

Fokus pada pengelolaan dan pengurangan produksi sampah serta menggunakan data untuk strategi pengolahan dan distribusi sampah.

3. Badan Penanggulangan Bencana Daerah (BPBD)

Menggunakan hasil clustering untuk mitigasi dan kesiapsiagaan banjir serta menentukan wilayah rawan dan strategi penanganan.

4. Perencana Kota / Bappeda

Menggunakan data sebagai dasar perencanaan pembangunan berkelanjutan dan mengintegrasikan hasil analisis ke dalam kebijakan jangka panjang.

5. Masyarakat dan Akademisi

Sebagai pengguna sekunder untuk memahami kondisi lingkungan dan mendukung penelitian lanjutan dan partisipasi publik.

2.2 Key Performance Indicator (KPI)

Key Performance Indicator (KPI) digunakan untuk mengukur keberhasilan sistem Dashboard BI dalam membantu analisis dan pengambilan keputusan terkait banjir dan produksi sampah di Jawa Barat. Adapun KPI yang digunakan adalah sebagai berikut:

1. Persentase wilayah dengan tingkat risiko banjir tinggi
Yaitu mengukur jumlah wilayah yang masuk dalam cluster resiko tinggi dibandingkan total wilayah.
2. Rata-rata volume produksi sampah per wilayah
Yaitu mengetahui rata-rata jumlah sampah yang dihasilkan setiap wilayah untuk melihat tingkat beban lingkungan.
3. Distribusi wilayah dalam setiap cluster (rendah, sedang, tinggi)
Yaitu menunjukkan jumlah wilayah pada masing-masing kategori
4. Tingkat korelasi antara produksi sampah dan kejadian banjir

Yaitu mengukur hubungan antara banyaknya sampah dengan tingkat banjir suatu wilayah.

5. Persentase wilayah prioritas penanganan

Yaitu mengidentifikasi wilayah yang memiliki tingkat banjir dan produksi sampah tinggi sebagai prioritas utama.

2.3 Business Question

Berikut adalah beberapa pertanyaan bisnis yang ingin dijawab melalui analisis dan dashboard BI:

1. Wilayah mana saja di Jawa Barat yang memiliki tingkat risiko banjir paling tinggi?
2. Bagaimana distribusi wilayah berdasarkan tingkat risiko banjir dan sampah?
3. Apakah terdapat hubungan antara tingginya produksi sampah dengan kejadian banjir?
4. Wilayah mana yang termasuk dalam kategori prioritas untuk penanganan lingkungan?
5. Bagaimana hasil segmentasi wilayah berdasarkan clustering K-Means?

III. DATASET

3.1 Sumber Dataset

Dataset diperoleh dari Open Data Jabar dengan judul Jumlah Kejadian Bencana Banjir Berdasarkan Kabupaten/Kota di Jawa Barat dan Jumlah Sampah yang Ditangani Berdasarkan Kabupaten/Kota di Jawa Barat

3.2 Deskripsi Dataset

Dataset yang digunakan dalam proyek ini merupakan dataset gabungan (multi-source) yang terdiri dari data jumlah kejadian banjir dan data jumlah sampah di Provinsi Jawa Barat. Dataset ini digunakan untuk menganalisis pola, tren, serta keterkaitan antara volume sampah dan kejadian banjir berdasarkan wilayah dan waktu.

Jumlah data: 243 baris

Jumlah fitur: 11 kolom

Struktur dan Atribut Dataset:

- id_banjir - ID unik untuk data banjir
- kode_provinsi - kode provinsi
- nama_provinsi - nama provinsi (Jawa Barat)
- kode_kabupaten_kota - kode wilayah kabupaten/kota
- nama_kabupaten_kota - nama wilayah kabupaten/kota
- jumlah_banjir - jumlah kejadian banjir
- satuan_banjir - satuan banjir (kejadian)
- tahun - tahun kejadian
- id_sampah - ID data sampah

- jumlah_sampah - jumlah sampah (dalam ton per hari)
- satuan_sampah - satuan sampah (ton per hari)

Contoh Tabel Dataset:

Wilayah	Tahun	Jumlah Banjir	Jumlah Sampah
Kabupaten Bogor	2015	5	861919.33
Kabupaten Sukabumi	2015	6	205690.23
Kabupaten Cianjur	2015	3	355554.29
Kabupaten Bandung	2015	11	1156523.00
Kabupaten Garut	2015	5	237389.82

Integrasi Data (Multi-Source)

Dataset ini merupakan hasil integrasi dari dua sumber data utama, yaitu data kejadian banjir dan data jumlah sampah. Integrasi dilakukan dengan menggabungkan data berdasarkan atribut yang sama, yaitu:

- nama_kabupaten_kota (wilayah)
- tahun (periode waktu)

Dengan adanya integrasi ini, dataset memungkinkan analisis yang lebih komprehensif untuk melihat hubungan antara jumlah sampah dan kejadian banjir di setiap wilayah dan waktu tertentu.

IV EKSPLORASI DATA (EDA)

4.1 Statistik Deskriptif

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 243 entries, 0 to 242
Data columns (total 11 columns):
#   Column                Non-Null Count  Dtype
---  -
0   id_banjir             243 non-null   int64
1   kode_provinsi         243 non-null   int64
2   nama_provinsi         243 non-null   object
3   kode_kabupaten_kota   243 non-null   int64
4   nama_kabupaten_kota   243 non-null   object
5   jumlah_banjir         243 non-null   int64
6   satuan_banjir         243 non-null   object
7   tahun                 243 non-null   int64
8   id_sampah             243 non-null   int64
9   jumlah_sampah         243 non-null   float64
10  satuan_sampah         243 non-null   object
dtypes: float64(1), int64(6), object(4)
memory usage: 21.0+ KB
(243, 11)
```

Berdasarkan hasil eksplorasi awal terhadap dataset, diperoleh informasi

bahwa dataset memiliki 243 baris data dan 11 kolom. Seluruh data tidak memiliki missing value, sehingga dataset dapat langsung digunakan untuk analisis lebih lanjut tanpa perlu proses pembersihan data yang kompleks.

Atribut dalam dataset terdiri dari tipe data numerik dan kategorikal, di mana variabel utama yang digunakan dalam analisis adalah `jumlah_banjir` dan `jumlah_sampah`. Kedua variabel ini akan menjadi fokus dalam analisis untuk menemukan pola dan hubungan antar data.


	id_banjir	kode_provinsi	kode_kabupaten_kota	jumlah_banjir	tahun	id_sampah	jumlah_sampah
count	243.000000	243.0	243.000000	243.000000	243.000000	243.000000	2.430000e+02
mean	203.000000	32.0	3231.333333	7.415638	2019.000000	122.000000	1.721056e+05
std	70.292247	0.0	31.266252	8.799657	2.587318	70.292247	3.917507e+05
min	82.000000	32.0	3201.000000	0.000000	2015.000000	1.000000	1.200000e+00
25%	142.500000	32.0	3207.000000	2.000000	2017.000000	61.500000	2.344100e+02
50%	203.000000	32.0	3214.000000	5.000000	2019.000000	122.000000	6.670600e+02
75%	263.500000	32.0	3273.000000	10.000000	2021.000000	182.500000	1.507118e+05
max	324.000000	32.0	3279.000000	75.000000	2023.000000	243.000000	2.075276e+06

Hasil statistik deskriptif menunjukkan bahwa:

- Variabel `jumlah_banjir` memiliki variasi nilai yang cukup beragam di setiap wilayah
- Variabel `jumlah_sampah` memiliki nilai yang relatif besar karena diukur dalam satuan ton per hari
- Terdapat perbedaan signifikan antara nilai minimum dan maksimum, yang menunjukkan adanya ketimpangan antar wilayah

4.2 Visualisasi Data

1) Distribusi Jumlah Banjir




Berdasarkan histogram distribusi jumlah banjir, terlihat bahwa

sebagian besar data berada pada rentang jumlah banjir yang rendah, yaitu di bawah 10 kejadian. Hal ini menunjukkan bahwa mayoritas wilayah di Provinsi Jawa Barat memiliki tingkat kejadian banjir yang relatif rendah.

Namun, terdapat beberapa data dengan jumlah banjir yang cukup tinggi (di atas 20 kejadian), bahkan mencapai lebih dari 70 kejadian. Kondisi ini menunjukkan adanya outlier atau wilayah dengan tingkat kerawanan banjir yang sangat tinggi dibandingkan wilayah lainnya. Distribusi data yang tidak merata (cenderung miring ke kanan/right skewed) mengindikasikan bahwa kejadian banjir tidak tersebar secara merata di seluruh wilayah, melainkan terkonsentrasi pada beberapa wilayah tertentu.

2) Distribusi Jumlah Sampah




Berdasarkan histogram distribusi jumlah sampah, terlihat bahwa sebagian besar wilayah memiliki jumlah sampah pada kategori rendah hingga sedang. Namun, terdapat beberapa wilayah dengan jumlah sampah yang sangat tinggi dibandingkan wilayah lainnya.

Distribusi data menunjukkan pola miring ke kanan (right skewed), dimana sebagian kecil wilayah menghasilkan volume sampah yang jauh lebih besar. Nilai maksimum yang tinggi mengindikasikan adanya ketimpangan produksi sampah antar wilayah.

Hal ini menunjukkan bahwa permasalahan sampah tidak terjadi secara merata, melainkan terkonsentrasi pada wilayah tertentu yang memiliki tingkat aktivitas dan kepadatan tinggi.


3) Hubungan Jumlah Sampah dan Banjir



Berdasarkan scatter plot hubungan jumlah sampah dan jumlah banjir, terlihat bahwa titik data menyebar dan tidak membentuk pola linear yang jelas. Sebagian besar data terkonsentrasi pada jumlah sampah rendah hingga sedang, dengan jumlah banjir yang bervariasi. Garis tren juga terlihat cenderung datar atau sedikit menurun, sehingga menunjukkan bahwa hubungan antara kedua variabel tergolong lemah.

Meskipun demikian, terdapat beberapa wilayah dengan jumlah sampah tinggi yang memiliki jumlah banjir tinggi, namun ada juga wilayah dengan jumlah sampah tinggi tetapi jumlah banjir rendah. Hal ini menunjukkan bahwa kejadian banjir tidak hanya dipengaruhi oleh jumlah sampah, tetapi juga oleh faktor lain seperti curah hujan, sistem drainase, kondisi geografis, dan pengelolaan lingkungan.

4) Tren Per Tahun



Berdasarkan grafik tren jumlah banjir per tahun, terlihat bahwa jumlah kejadian banjir mengalami fluktuasi dari tahun 2015 hingga 2023. Jumlah banjir meningkat pada tahun 2016, kemudian menurun hingga 2018, dan kembali naik secara signifikan mulai 2019 hingga 2021, sebelum mengalami penurunan lagi pada tahun 2022 dan 2023.

mencapai puncaknya pada 2021. Setelah itu, jumlah banjir mengalami penurunan pada tahun 2022 dan 2023. Hal ini menunjukkan bahwa kejadian banjir tidak stabil setiap tahun dan dipengaruhi oleh berbagai faktor seperti curah hujan, kondisi lingkungan, dan sistem drainase.

4.3 Insight Awal

Berdasarkan hasil eksplorasi data dan visualisasi yang telah dilakukan, diperoleh beberapa insight awal sebagai berikut:

- Sebagian besar wilayah di Provinsi Jawa Barat memiliki jumlah kejadian banjir yang relatif rendah, namun terdapat beberapa wilayah dengan jumlah kejadian yang sangat tinggi, sehingga menunjukkan adanya ketimpangan tingkat kerawanan banjir antar wilayah.
- Distribusi jumlah sampah menunjukkan perbedaan yang cukup signifikan antar wilayah, di mana beberapa wilayah menghasilkan volume sampah yang jauh lebih besar dibandingkan wilayah lainnya.
- Pola distribusi pada variabel jumlah banjir dan jumlah sampah cenderung tidak merata (right skewed), yang mengindikasikan bahwa permasalahan lebih terkonsentrasi pada wilayah tertentu.
- Berdasarkan analisis scatter plot, hubungan antara jumlah sampah dan jumlah banjir tergolong lemah karena tidak terlihat pola linear yang jelas.
- Meskipun hubungan keduanya tidak kuat, terdapat beberapa wilayah dengan jumlah sampah tinggi yang juga memiliki jumlah kejadian banjir tinggi, sehingga pengelolaan sampah tetap menjadi salah satu faktor penting dalam mitigasi banjir.
- Tren jumlah banjir per tahun menunjukkan pola yang fluktuatif, dengan peningkatan signifikan pada tahun tertentu, terutama sekitar 2020–2021, sebelum kembali menurun pada tahun berikutnya.
- Secara keseluruhan, permasalahan banjir dan sampah perlu ditangani secara terintegrasi dengan mempertimbangkan faktor lain seperti curah hujan, sistem drainase, kondisi geografis, dan tata kelola lingkungan.

V ETL (EXTRACT, TRANSFORM, LOAD)

5.1 Extract

```
import pandas as pd

# Extract data dari file CSV
df = pd.read_csv('data.csv')

# menampilkan 5 data pertama
df.head()
```

Output:

	id_banjir	kode_provinsi	nama_provinsi	kode_kabupaten_kota	nama_kabupaten_kota	jumlah_banjir	satuan_banjir	tahun	id_sampah	jumlah_sampah	satuan_sampah
0	82	32	JAWA BARAT	3201	KABUPATEN BOGOR	5	KEJADIAN	2015	1	861919.33	TON PER HARI
1	83	32	JAWA BARAT	3202	KABUPATEN SUKABUMI	6	KEJADIAN	2015	2	205690.23	TON PER HARI
2	84	32	JAWA BARAT	3203	KABUPATEN CIANJUR	3	KEJADIAN	2015	3	355554.29	TON PER HARI
3	85	32	JAWA BARAT	3204	KABUPATEN BANDUNG	11	KEJADIAN	2015	4	1156523.00	TON PER HARI
4	86	32	JAWA BARAT	3205	KABUPATEN GARUT	5	KEJADIAN	2015	5	237389.82	TON PER HARI

Tahap extract merupakan proses pengambilan data dari sumber yang telah ditentukan. Pada proyek ini, data diambil dari file **CSV** yang berisi informasi jumlah kejadian banjir dan jumlah sampah di Provinsi Jawa Barat.

Proses extract dilakukan menggunakan library **pandas** pada Python dengan fungsi `read_csv()`. Hasil dari proses ini adalah dataset mentah dengan 243 baris dan 11 kolom yang siap untuk dianalisis lebih lanjut.

5.2 Transform

1. Cek Missing Value

```
# CEK MISSING VALUE
print("Missing Value:")
print(df.isnull().sum())

df = df.dropna()
```

Output:

```
... Missing Value:
id_banjir          0
kode_provinsi      0
nama_provinsi      0
kode_kabupaten_kota 0
nama_kabupaten_kota 0
jumlah_banjir      0
satuan_banjir      0
tahun             0
id_sampah          0
jumlah_sampah      0
satuan_sampah      0
dtype: int64
```

2. Cek Data Duplikat

```
df = df.drop_duplicates()
```

3. Pemilihan Kolom yang Relevan

```
df_clean = df[['kode_provinsi', 'nama_provinsi',
               'kode_kabupaten_kota', 'nama_kabupaten_kota',
               'tahun', 'jumlah_banjir', 'jumlah_sampah']]
```

4. Penyesuaian Format Data

```
df_clean['tahun'] = df_clean['tahun'].astype(int)
df_clean['jumlah_banjir'] = df_clean['jumlah_banjir'].astype(int)
df_clean['jumlah_sampah'] = df_clean['jumlah_sampah'].astype(float)
```

5. Cek Hasil Transform

```
df_clean.head()
```

Output:

	kode_provinsi	nama_provinsi	kode_kabupaten_kota	nama_kabupaten_kota	tahun	jumlah_banjir	jumlah_sampah
0	32	JAWA BARAT	3201	KABUPATEN BOGOR	2015	5	861919.33
1	32	JAWA BARAT	3202	KABUPATEN SUKABUMI	2015	6	205690.23
2	32	JAWA BARAT	3203	KABUPATEN CIANJUR	2015	3	355554.29
3	32	JAWA BARAT	3204	KABUPATEN BANDUNG	2015	11	1156523.00
4	32	JAWA BARAT	3205	KABUPATEN GARUT	2015	5	237389.82

Tahap transform dilakukan untuk membersihkan dan menyesuaikan data agar siap digunakan dalam analisis dan pembangunan data warehouse.

Proses yang dilakukan meliputi:

- Pengecekan missing value, yang menunjukkan bahwa tidak terdapat data yang hilang pada dataset sehingga data dapat langsung digunakan
- Pengecekan data duplikat, dilakukan untuk memastikan tidak ada data yang berulang yang dapat mempengaruhi hasil analisis
- Pemilihan kolom yang relevan, dilakukan pemilihan kolom-kolom yang diperlukan untuk analisis, yaitu data lokasi (kode_provinsi, nama_provinsi, kode_kabupaten_kota, nama_kabupaten_kota), data waktu (tahun), serta data utama yang dianalisis (jumlah_banjir dan jumlah_sampah). Sedangkan kolom seperti id_banjir, id_sampah, satuan_banjir dan satuan_sampah tidak digunakan karena tidak berpengaruh langsung terhadap analisis.
- Penyesuaian format data, memastikan tipe data sesuai
 - Tahun → integer
 - Jumlah_banjir → integer
 - Jumlah_sampah → float

Hasil dari tahap transform adalah dataset yang lebih bersih, terstruktur, dan siap untuk digunakan dalam proses analisis lebih lanjut maupun pembangunan data warehouse.

5.3 Load

```
dim_waktu.to_csv('/content/dim_waktu.csv', index=False)
dim_lokasi.to_csv('/content/dim_lokasi.csv', index=False)
fact_banjir_sampah.to_csv('/content/fact_banjir_sampah.csv', index=False)

print("ETL selesai")
```

Output:

```
ETL selesai
```

Download file hasil ETL

```
from google.colab import files
files.download('/content/dim_waktu.csv')
files.download('/content/dim_lokasi.csv')
files.download('/content/fact_banjir_sampah.csv')
```


Tahap load dilakukan dengan menyimpan dataset hasil transformasi ke dalam file baru dengan format CSV. Dataset ini merupakan hasil dari proses pembersihan dan penyesuaian data yang telah dilakukan pada tahap transform.

Data yang telah disimpan ini akan digunakan sebagai sumber utama dalam proses analisis lanjutan serta dalam perancangan data warehouse. Dengan demikian, proses ETL yang dilakukan telah menghasilkan data yang bersih, terstruktur, dan siap untuk digunakan dalam mendukung pengambilan keputusan berbasis data.

VI DATA WAREHOUSE

6.1 Skema Data Warehouse

Jenis skema yang digunakan adalah Star Schema, karena memiliki satu tabel fakta di tengah dan beberapa tabel dimensi.



6.2 Fact Table

1. Nama Tabel Fakta

fact_banjir_sampah, tabel ini menyimpan data utama yang akan dianalisis.

2. Measure

- a) jumlah_banjir
- b) jumlah_sampah

3. Struktur

Kolom	Fungsi
id_fakta	Primary key untuk setiap baris data
id_waktu	Foreign key yang terhubung ke tabel dim_waktu
id_lokasi	Foreign key yang terhubung ke tabel dim_lokasi
jumlah_banjir	Jumlah kejadian banjir
jumlah_sampah	Jumlah volume sampah

Contoh isi tabelnya:

	id_fakta	id_waktu	id_lokasi	jumlah_banjir	jumlah_sampah
0	1	1	1	5	861919.33
1	2	1	2	6	205690.23
2	3	1	3	3	355554.29
3	4	1	4	11	1156523.00
4	5	1	5	5	237389.82

6.3 Dimension Table

1. Dimensi Waktu (dim_waktu)

Tabel ini berisi informasi waktu yang digunakan untuk analisis tren.
Yaitu : id_waktu dan tahun

Contohnya:

	id_waktu	tahun
0	1	2015
1	2	2016
2	3	2017
3	4	2018
4	5	2019

2. Dimensi Lokasi (dim_lokasi)

Tabel ini berisi informasi lokasi wilayah.

Yaitu: id_lokasi, kode_provinsi, nama_provinsi, kode_kabupaten_kota, nama_kabupaten_kota.

Contohnya:

	id_lokasi	kode_provinsi	nama_provinsi	kode_kabupaten_kota	nama_kabupaten_kota
0	1	32	JAWA BARAT	3201	KABUPATEN BOGOR
1	2	32	JAWA BARAT	3202	KABUPATEN SUKABUMI
2	3	32	JAWA BARAT	3203	KABUPATEN CIANJUR
3	4	32	JAWA BARAT	3204	KABUPATEN BANDUNG
4	5	32	JAWA BARAT	3205	KABUPATEN GARUT


VII Analisis Data Mining

7.1 Metode yang Digunakan

Metode yang digunakan dalam analisis ini adalah K-Means Clustering, yaitu teknik unsupervised learning yang digunakan untuk mengelompokkan wilayah di Provinsi Jawa Barat berdasarkan jumlah banjir dan jumlah sampah.

Tahapan yang dilakukan:

1. Menentukan variabel clustering
 - 1) Jumlah_banjir
 - 2) Jumlah_sampah
2. Melakukan normalisasi data menggunakan StandardScaler
3. Menentukan jumlah cluster optimal menggunakan Elbow Method



Berdasarkan grafik elbow, jumlah cluster yang dipilih adalah 3 cluster karena penurunan inertia mulai melandai setelah titik itu.

7.2 Alasan Pemilihan Metode

Metode K-Means dipilih karena mampu mengelompokkan data secara efisien berdasarkan kemiripan karakteristik tanpa memerlukan label. Metode ini cocok digunakan untuk mengidentifikasi kelompok wilayah berdasarkan tingkat risiko banjir dan volume sampah.

7.3 Konsep Metode

K-Means adalah algoritma clustering yang bekerja dengan cara mengelompokkan data berdasarkan kedekatan jarak terhadap centroid.

Langkah-langkah K-Means:

1. Menentukan jumlah cluster (K)
2. Menginisialisasikan centroid awal
3. Menghitung jarak ke centroid
4. Mengelompokkan data ke cluster terdekat
5. Mengupdate centroid
6. Mengulang hingga konvergen

7.4 Hasil Analisis

Hasil clustering menghasilkan 3 cluster wilayah

- 1) Cluster 0 (Wilayah Risiko Rendah)


- Dimana rata-rata banjir rendah dan sampah rendah
- 2) Cluster 1 (Wilayah Risiko Sedang)
Dimana banjir sedang dengan sampah sangat tinggi
 - 3) Cluster 2 (Wilayah Risiko Tinggi)
Dimana banjir tinggi dan sampah tinggi

Hasil evaluasi model:

```
=== Evaluasi Clustering ===  
Silhouette Score : 0.707  
Davies-Bouldin Index : 0.655  
Calinski-Harabasz : 213.224
```


Visualisasi Hasil:

1. Visualisasi Cluster Wilayah Berdasarkan Sampah dan Banjir



Visualisasi scatter plot menunjukkan hubungan antara jumlah sampah dan jumlah kejadian banjir yang telah dikelompokkan ke dalam beberapa cluster. Terlihat bahwa data tersebar dalam tiga kelompok utama, yaitu risiko rendah, sedang dan tinggi. Sebagian besar wilayah berada pada area dengan nilai banjir rendah, namun terdapat beberapa titik yang menunjukkan banjir dengan sampah tinggi. Hal ini mengindikasikan bahwa meskipun hubungan tidak sepenuhnya linear, terdapat kecenderungan bahwa wilayah dengan sampah tinggi memiliki risiko banjir yang lebih besar.

2. Visualisasi Peta Folium



Visualisasi peta digunakan untuk menunjukkan persebaran geografis cluster wilayah di Jawa Barat. Setiap titik merepresentasikan kabupaten/kota dengan warna berbeda sesuai kategori.

Dari peta terlihat bahwa:

1. Wilayah risiko rendah tersebar cukup merata
2. Wilayah risiko sedang muncul di beberapa titik dengan produksi sampah tinggi
3. Wilayah risiko tinggi terkonsentrasi pada wilayah tertentu

Visualisasi membantu dalam mengidentifikasi lokasi prioritas penanganan secara spasial, sehingga lebih mudah digunakan dalam pengambilan keputusan.

7.5 Interpretasi

Interpretasi Hasilnya:

1. Wilayah risiko rendah relatif aman dan memerlukan pemantauan rutin
2. Wilayah risiko sedang memiliki permasalahan utama pada produksi sampah
3. Wilayah risiko tinggi menjadi prioritas utama dalam penanganan banjir dan pengelolaan lingkungan.

DAFTAR PUSTAKA